KNDA K-뉴딜 아카데미 posco

펌프 모델 비교와 점검 보고서 자동화

프로젝트 개발 기획서

2026 년 11 월 9 일 | 팀장 박민호 | 강민준 김수민 이하일 이한결

1 개발 목적과 구현 범위

왜 필요한가: 모델 결과를 확인한 뒤에도 현장 관찰 정리, 근거 검색, 보고서 작성과 담당자 간 전달이 남기 때문이다.

전처리된 펌프 데이터를 받아 모델을 비교하고, 사람이 선택한 결과와 현장 관찰을 연결한다. LLM 은 관련 문서를 찾아 점검 보고서 초안을 작성한다. 담당자가 내용을 검토하고 판단과 진행 상태를 직접 남긴다.

이번 목표는 3~5 번 기능이 한 흐름으로 동작하는 것이다. 5 번까지 검증을 마치면 6 번 비용 비교를 추가한다. 특정 공정과 펌프 모델은 고정하지 않는다.

번호	기능	이번 범위	난도
1·2	데이터 준비	사람이 노트북에서 진단·분할·전처리·파생변수 생성. 소프트웨어는 업로드 형식만 확인.	외부
필수	계정 인증	로그인·로그아웃과 세션 인증. 인증한 계정으로 작성·수정 이력 기록.	하
3	모델 비교와 선택	학습 완료 모델을 검증 지표 순위로 정렬. 최종 선택은 사용자가 결정.	중
4	RAG 사후 지원	관찰·모델 결과·검색 근거를 구분해 점검 보고서 초안 작성.	중
5	저장과 보고서	결과·관찰·출처·진척을 저장하고 다시 열기 및 보고서 출력.	중
6	비용 비교	필수 흐름 통과 후 두 시나리오의 점검·수리·중단 비용 비교.	중
향후	범용 자동 분석	임의 CSV 해석과 자동 전처리 결정은 향후 구현 목표. 3D 탐색도 이번 범위에서 제외.	상

난도는 팀의 계획 기준이다. 하: 독립적인 기본 기능 / 중: 데이터·화면·저장 연동 / 상: 추가 데이터나 현장 검증이 필요한 기능. 이번 범위의 개발 계획이며 완료 실적이 아니다.

구성 2 데이터셋 · 3 처리 흐름 · 4 모델 화면 · 5 점검 보고서 · 6 비용 비교 · 7 역할과 일정 · 8 RAG 조사 · 9 검증과 제출

2 데이터셋과 검증 범위

왜 필요한가: 상태 라벨과 데이터 누락을 구분해야 모델 결과를 제대로 해석할 수 있기 때문이다.

Kaggle Pump Sensor Data 로 기능을 검증한다. 공개 물 펌프 데이터이며 철강 현장 데이터는 아니다. 적용 장비가 정해지면 해당 데이터와 매뉴얼로 교체할 수 있게 구성한다. [1]

항목	원자료 확인 내용
파일	sensor.csv / 220,320 행 / 55 열
기간과 간격	2018-04-01 00:00 ~ 2018-08-31 23:59 / 1 분 간격 / 시간대 정보 미제공
컬럼	sensor_00~sensor_51 총 52 개, timestamp, machine_status, 내보낸 행 번호
상태	NORMAL 205,836 행 / RECOVERING 14,477 행 / BROKEN 7 행
누락	sensor_15 는 전체 결측. sensor_50 은 약 34.96% 결측. 11 행은 모든 채널이 비어 있음.
확인되지 않은 정보	센서별 단위·위치의 원제공자 확인, 고장 원인, 실제 정비·생산중단 시간, 비용, 설비 모델

원자료를 직접 집계했다. 원본 상태는 보존하고 학습용 label 을 별도로 생성한다. Normal=0, UnNormal=1 이다.

분류 목표와 평가 한계

Normal 은 NORMAL 205,836 행, UnNormal 은 BROKEN 과 RECOVERING 을 합친 14,484 행이다. 이 두 상태로 분류한다. UnNormal 에는 회복 상태가 대부분 포함되므로 고장 발생만을 맞히는 성능으로 해석하지 않는다.

RECOVERING 은 기록된 상태 이름이다. 이를 실제 수리시간이나 생산중단 시간으로 자동 변환하지 않는다. 모든 센서가 비어 있는 NORMAL 행도 있어 설비 상태와 데이터 누락을 구분해야 한다.

사람이 확정할 데이터 준비 기준

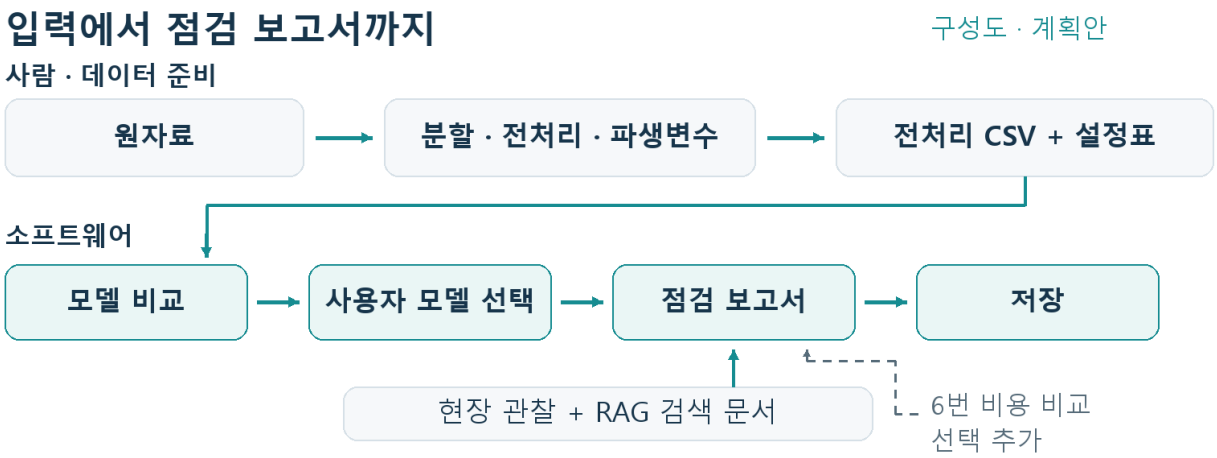
행 번호와 정답에서 만든 변수는 특징에서 제외한다. 담당자가 결측 처리와 제외 이유·표본 수를 기록한다. 보정·스케일링·특징 선택·이상치 기준은 학습 자료에서만 정한다. 파생변수와 결측 보정에는 해당 시점 이후 값을 쓰지 않는다. [2]

분할 기본안	기간	UnNormal 수
학습	4 월 1 일 ~ 5 월 31 일	5,975
검증	6 월 1 일 ~ 7 월 4 일	8,391
시험	7 월 5 일 ~ 8 월 31 일	118

회복 구간을 중간에서 나누지 않은 분할안이다. 개발 시작 시 확정하고 전처리 후 표본 수를 다시 센다. 이미 전체 자료를 조사했으므로 외부 독립 검증으로 주장하지 않는다.

3 처리 흐름과 데이터 전달

왜 필요한가: 데이터와 설정의 전달 형식을 맞춰야 담당자별 개발을 병렬로 진행할 수 있기 때문이다.



사람이 준비한 데이터와 설정을 받아 모델 실행부터 보고서 저장까지 연결하는 개발안이다.

업로드할 파일

파일	필수 내용
prepared.csv	timestamp, label(0=Normal, 1=UnNormal), split(train/valid/test), 숫자형 특징. machine_status 는 원본 상태 확인용으로 보존하고 특징에서 제외.
analysis_config.json	데이터 버전, 특징 목록과 순서, 분할 경계, 결측·스케일링·파생변수 처리 내역, 라벨 정의, 그래프 단위·전처리 여부.

소프트웨어는 필수 열·자료형·유한한 수치·시각 중복·분할 순서를 확인한다. 오류가 있으면 원인과 위치를 알려주고 담당자가 파일을 수정하게 한다. 결측치를 몰래 채우거나 특징을 자동 추가하지 않는다.

구현 구조

영역	개발안
화면	React 기반 로그인·모델 비교·보고서·기록 화면. 계정 인증은 필수이며 작성자·수정자를 로그인 계정에서 기록.
서버	FastAPI 에서 비밀번호 해시·세션 인증, 파일 확인·모델 실행·지표·비용 계산. 미인증 접근 차단, 한 번에 한 학습 작업 실행.
저장	SQLite 와 서버 파일 저장소에 실행 ID 별 데이터 버전·설정·결과·보고서 버전 저장.
LLM	서버가 현장 관찰·선택 구간의 모델 결과·검색 문서를 API 로 전달. API 키는 서버 환경변수에 보관. 원자료 전체를 보내지 않음.

패키지 버전과 기본 모델 설정은 개발 시작 때 고정한다. 기업용 인증, 무제한 파일 지원, 대규모 동시 학습은 이번 범위에 포함하지 않는다.

4 모델 비교와 선택 화면

왜 필요한가: 학습한 모델의 평가 결과를 높은 순서로 비교하고 사용자가 목적에 맞는 모델을 선택할 수 있어야 하기 때문이다.



와이어프레임이다. 수치는 실행 후 표시하며 현재 성능을 주장하지 않는다.

사용 순서

① 로그인·데이터 확인 → ② 학습할 모델 선택 → ③ 검증 지표 내림차순 정렬 → ④ 사용자가 모델 선택 → ⑤ 시험 평가 → ⑥ 결과 저장

비교 기준과 완료 조건

학습을 마친 모델을 검증 지표가 높은 순서로 정렬한다. 기본은 UnNormal F1 이며 사용자가 Precision·Recall 등 정렬 기준을 바꿀 수 있다. 순위와 관계없이 최종 모델은 사용자가 선택한다. 두 클래스의 지표·표본 수와 2×2 혼동행렬을 함께 표시한다.

학습 데이터 자체의 점수와 검증 점수를 구분한다. 순위에는 같은 검증셋의 점수를 사용하며 시험 결과는 선택 후 따로 표시한다. 시험 결과를 보고 다시 선택하면 독립 검증으로 주장하지 않는다. [2, 3]

계산할 수 없는 지표는 사유와 함께 표시한다. 시험셋에 없는 클래스는 평가 불가로 구분한다. 학습이 실패해도 다른 결과는 보존한다. 그래프에는 원단위인지 전처리 후 수치인지 표시한다.

5 현장 관찰과 점검 보고서

왜 필요한가: 관찰 기록과 모델 결과가 따로 있으면 근거를 다시 찾고 보고서를 반복 작성해야 하기 때문이다.



관찰 문장은 시연용 입력 예시다. Kaggle 의 실제 현장 관찰이나 확인된 고장 사실이 아니다.

LLM 이 맡는 일

사람이 입력한 관찰, 서버가 계산한 모델 결과, 검색 문서의 근거를 구분해 요약한다. 추가 확인 항목과 담당자에게 전달할 점검 보고서 초안을 만든다. 지표 계산, 고장 확정, 조치 완료 판단은 맡기지 않는다.

예를 들어 "펌프 아래 물이 고여 있음"을 입력하면 누수 위치·씰 형식·발생 조건을 확인할 항목으로 제시한다. 패킹과 메커니컬 씰은 누수의 해석이 다르므로 형식이 없으면 먼저 확인하도록 한다. [4]

사람이 판단하고 저장하는 일

보고서는 초안에서 검토를 거쳐 확정한다. 점검의 검토 전·확인 중·완료 상태와 담당자는 사람이 변경한다. 확정 보고서를 수정하면 새 버전으로 저장하고 다시 검토한다.

새로고침하거나 다른 브라우저에서 열어도 같은 서버의 기록을 조회한다. 저장한 버전을 HTML 보고서로 내려받고 인쇄 기능으로 PDF 를 저장한다. LLM 호출 실패 시 관찰과 결과를 보존하고 재시도한다.

6 비용 시나리오 비교

왜 필요한가: 점검과 수리 대안을 논의할 때 비용의 가정과 계산 근거를 함께 보여줘야 판단 내용을 공유하기 쉽기 때문이다.

5 번까지 통과하면 추가한다. AI 가 먼저 선택 모델의 평가 결과·분류 결과·관련 구간을 확인하고 현장 관찰과 연결한다. 그다음 비용 근거와 입력 가정을 확인해 두 시나리오를 비교한다.



미입력 값은 0 원으로 간주하지 않는다. 제외한 항목과 이유를 표시한다.

계산과 설명의 역할

서버 계산식 점검비 + 수리비 + 예상 생산중단시간 × 시간당 손실

비용 차이 기준 시나리오 비용 – 비교 시나리오 비용

모델 결과가 없으면 먼저 실행·선택을 안내한다. LLM 은 모델 결과를 근거로 점검 필요성을 요약한 뒤, 사용자가 입력한 금액·중단시간과 서버 계산 결과를 설명한다. 시간·통화를 통일하고 중복 비용을 확인한다.

근거와 범위

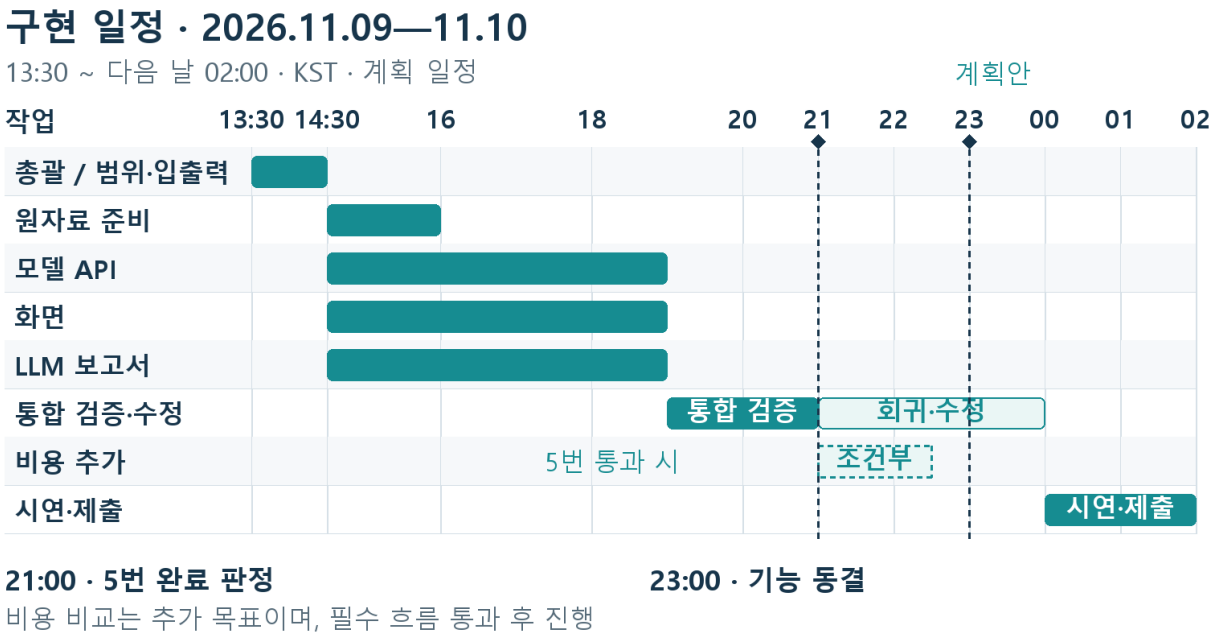
DOE 의 펌프 생애주기비용 지침에서 비용 항목과 비교 원칙을 참고한다. 2001 년 사례 가격을 현재 단가로 쓰지 않는다. 이번 계산은 정비·중단 비용 비교이며 전체 LCC 계산이나 입증된 절감액이 아니다. [5]

분류 확률을 실제 고장 확률로 해석하거나, 모델 정확도를 비용 절감률로 바꾸지 않는다.
에너지비·할인율·장기 교체 최적화는 후속 확장 범위로 둔다.

7 역할 분담과 개발 일정

왜 필요한가: 각자 만든 기능을 마지막에 한꺼번에 합치지 않도록 입력 형식과 연결 시점을 먼저 맞춰야 하기 때문이다.

팀원	담당	주요 전달물
박민호 팀장	RAG 기반 챗봇 개발	문서 검색, 모델 결과 연결, 보고서·비용 설명
강민준	시계열 분석	시간별 변화 분석, 분할 기준, 이상 구간 근거
김수민	데이터 분석·EDA·전처리	데이터 품질 점검, 이진 라벨, 전처리 CSV·설정
이하일	해석·문서 정리	분석 결과 해석, 점검 보고서 구조, 근거 정리
이한결	RAG 자료 조사	도메인·정비·비용 자료, 원문·페이지·적용 조건



연결 시점과 중단 기준

14:30 까지 입력 형식·분할·모델 기본값·API 응답 형식·LLM 연결을 확인한다. 16:00 에 데이터 전달, 19:00 에 화면과 서버 연결, 21:00 에 업로드부터 보고서 재조회까지 검증한다.

21:00 검증을 통과하면 비용 비교를 추가한다. 늦으면 6 번을 보류하고 5 번까지 마무리한다. 23:00 부터 기능 추가를 멈추고 오류를 수정한다. 00:00~01:30 시연·제출물 확인, 01:30~02:00 제출 확인과 예비 시간으로 사용한다.

2026-11-09 13:30 시작, 2026-11-10 02:00 마감 기준의 계획이며 모든 시간은 KST 다. 자료 조사는 14:30~16:00 우선 수행하고 이후 필요한 근거만 보완한다.

8 RAG 자료 조사와 연결 기준

왜 필요한가: 출처가 있는 문장만 보고서에 연결하고, 다른 설비의 기준을 그대로 적용하는 일을 막기 위해서다.

먼저 누수 관찰을 정리하는 한 사례에 필요한 자료를 모은다. 그다음 진동·소음·유량 저하로 범위를 넓힌다. 특정 공정과 펌프 모델은 선정 후 해당 자료로 보완한다.

순서	조사 자료	가져올 내용
1	제조사 운전·정비 매뉴얼	적용 모델·형식, 씰·베어링·커플링 구성, 점검 항목과 조건. 모델 미정이면 일반 원심펌프 자료로 범위를 표시.
2	증상별 점검 자료	누수·진동·소음·유량 저하의 가능한 원인, 구분에 필요한 관찰, 확인할 운전 조건.
3	점검 보고서와 작업 기록 양식	설비 식별, 발생 시각, 위치, 증상, 측정 결과, 담당자, 조치·후속 확인·완료 기준.
4	공정과 배관 자료	대상이 정해진 뒤 운전 모드, 물의 경로, 밸브·예비 펌프 관계 확인. 현 단계에서 특정 공정으로 고정하지 않음.
5	비용 산정 지침	DOE LCC 의 항목·비교 조건·입력값 정의. 이번에는 정비·중단 비용만 사용.
6	실제 비용·정비 사례	연도·통화·설비 조건·포함 비용 확인. 사례 가격을 대상 설비의 실제 금액으로 제시하지 않음.

자료마다 남길 정보

문서명 / 발행기관 / 연도·판본 / 적용 설비·모델 / 원문 링크 / 페이지 또는 절 / 핵심 내용 / 적용 조건 / 이 근거로 답할 질문

원문과 핵심 번역을 함께 남긴다. 동일 내용을 반복한 블로그보다 제조사·공공기관 원문을 우선한다. 공개 원문이 없거나 적용 조건을 확인할 수 없으면 그 한계를 기록한다.

RAG 구현과 확인

문서를 제목·절 단위로 나누고 페이지·링크·적용 조건을 붙인다. 질문과 관찰에 관련된 문단을 검색해 LLM 에 전달한다. 답변에는 사용한 근거 번호를 표시하고 원문으로 이동할 수 있게 한다.

첫 평가 질문은 "펌프 아래 물이 고였다. 무엇을 추가 확인하고 보고서에 남겨야 하나?"로 둔다. 씰 형식 미확인, 근거 없는 질문, 관찰과 모델 결과가 다른 질문도 확인한다. 근거가 없으면 부족한 정보를 명시하고 원인을 확정하지 않는다.

기본 자료: KSB Maintenance [4], DOE Pump Life Cycle Costs [5]. 비용 지침은 정비 매뉴얼을 대신하지 않으며 CSV 의 익명 센서에 단위나 위치를 부여하는 자료로 쓰지 않는다.

9 완료 기준과 제출물

왜 필요한가: 화면이 보이는 것과 실제 사용 흐름이 끝까지 동작하는 것을 구분해 마감 전에 검증하기 위해서다.

검증 항목	통과 기준
계정 인증	로그인·로그아웃·세션 유지 및 미인증 접근 차단. 작성자·수정자를 인증 계정으로 기록.
데이터 전달	전처리 파일·설정표에서 Normal·UnNormal 라벨, 분할, 특징 순서 확인. 오류 파일은 수정 항목 안내.
모델 비교	같은 검증 지표로 내림차순 정렬. 사용자가 정렬 기준과 모델을 선택하고 시험 평가를 별도 저장.
사후 처리	관찰·모델 결과·문서 근거를 분리한 초안 생성. 문서 링크·페이지와 내용 일치 확인.
저장과 출력	새로고침·다른 브라우저에서 조회. 수정·진척을 작성자·시각·버전과 함께 보존. HTML 출력물에 저장 버전의 관찰·결과·출처 포함.
비용 추가 구현한 경우	모델 결과를 먼저 확인한 뒤 비교. 계산 예제 일치, 누락·음수·단위 오류 처리, 가정·제외 항목 표시.
실패 처리	학습·LLM 호출 실패 시 기존 결과 보존과 재시도. 없는 지표·출처·승인·완료 사실을 만들지 않음.

시연과 산출물

전처리 파일 업로드 → 모델 비교·선택 → 관찰 입력 → 근거가 포함된 보고서 초안 → 사람이 수정·확정 → 저장·재조회 순서로 시연한다. 비용 비교는 구현과 검증이 끝났을 때만 추가한다.

제출물은 개발 기획서, 실행 가능한 코드와 실행 안내, 전처리 노트북·설정, 모델 평가 기록, 점검 보고서 예시, 시연 영상이다. 원본 데이터는 이용 조건을 확인하고 다운로드 경로로 안내한다.

성능 목표값이나 절감률을 미리 만들지 않는다. 모델은 기준 모델과 비교해 실제 지표를 기록한다. 보고서 작성 시간은 동일 사례를 수동 작성한 경우와 비교 측정하고, 오류·수정 횟수를 함께 남긴다.

참고 자료

[1] Kaggle Pump Sensor Data 공개 데이터 출처

[2] scikit learn Common pitfalls 전처리 누수와 학습 데이터 기준

[3] scikit learn TimeSeriesSplit 시간 순서를 고려한 평가

[4] KSB Maintenance 씰 형식과 점검 항목

[5] DOE HI Europump Pump Life Cycle Costs 2001 년 요약본